

MÓDULO: *Implementación de Soluciones de Inteligencia Artificial Aplicada a los Negocios*

Duración: 12 clases (3 h c/u) → 4 semanas

Dataset base: *Olist Brazilian E-Commerce Dataset*

Equipos: 10 grupos (1 Ingeniero de Datos + 1 Científico de Datos + 1 Product Owner)

Producto final: MVP funcional de IA desplegable y monitoreable

1. OBJETIVO GENERAL

Desarrollar en los estudiantes la capacidad de diseñar, implementar y evaluar soluciones de Inteligencia Artificial (IA) orientadas a la generación de valor empresarial, usando metodologías ágiles y considerando aspectos técnicos, éticos y de gobernanza.

2. Presentación del Dataset

El **Olist Brazilian E-Commerce Dataset** es una base de datos pública ampliamente utilizada en la investigación académica y en competencias de ciencia de datos. Contiene información real de transacciones de comercio electrónico de la plataforma **Olist**, una de las mayores empresas de e-commerce en Brasil.

2.1. Estructura general

El dataset está compuesto por **9 tablas principales** interconectadas mediante claves relacionales, lo que lo convierte en un excelente entorno para el trabajo colaborativo y la aplicación de metodologías de *Data Science* a nivel empresarial:

Tabla	Descripción	Clave principal
olist_orders_dataset.csv	Registra cada pedido: fechas, estatus, cliente y vendedor.	order_id
olist_customers_dataset.csv	Información de los clientes: ciudad, estado, geolocalización.	customer_id
olist_order_items_dataset.csv	Detalle de productos en cada pedido (SKU, precios, flete).	order_item_id
olist_products_dataset.csv	Descripción de productos, categorías y dimensiones.	product_id
olist_sellers_dataset.csv	Información de los vendedores asociados a Olist.	seller_id
olist_geolocation_dataset.csv	Coordenadas de ubicaciones por ciudad y estado.	geolocation_zip_code_prefix
olist_order_reviews_dataset.csv	Calificaciones, comentarios y sentimiento de los compradores.	review_id

olist_order_payments_dataset.csv	Métodos de pago y valores de las transacciones.	order_id
product_category_name_translation.csv	Traducción de categorías de producto.	product_category_name

2.2. Características

- **Volumen:** más de **100.000 registros** distribuidos en múltiples tablas.
- **Tipo:** datos estructurados, relacionales y temporales.
- **Periodo:** pedidos entre **2016 y 2018**.
- **Dominios cubiertos:** ventas, logística, satisfacción del cliente, finanzas y producto.

2.3. Potencial analítico

Este dataset permite simular un **ecosistema empresarial completo**, abarcando la cadena de valor del comercio electrónico.

Por su estructura, se puede aplicar una amplia gama de técnicas de IA y analítica avanzada:

- Predicción de satisfacción y churn.
- Forecast de demanda y ventas.
- Detección de retrasos en la entrega.
- Segmentación de clientes o vendedores.
- Recomendación de productos.
- Detección de fraudes o anomalías.

3. Descripción del trabajo en grupos

Durante el módulo, los estudiantes se organizarán en **equipos de 3 integrantes** que formarán una **célula de desarrollo ágil de IA**.

Cada equipo deberá **diseñar, implementar y presentar un MVP (Minimum Viable Product)** de una solución de Inteligencia Artificial que resuelva un problema real derivado del dataset Olist.

3.1. Descripción general del trabajo

Cada grupo:

1. **Se le asignará un problema de negocio** (ej. predicción de satisfacción, optimización de tiempos de entrega, segmentación de clientes, etc.).
2. **Desarrollar un pipeline de IA completo**, desde la ingeniería de datos hasta el despliegue del modelo.
3. **Trabajar en sprints semanales**, entregando avances iterativos.
4. **Aplicar métricas técnicas y de negocio**, justificando el impacto de su modelo.
5. **Desarrollar un dashboard y API funcional** para mostrar los resultados.
6. **Evaluar consideraciones éticas, de gobernanza y sostenibilidad del modelo**.

3.2. Entregables finales (Puede Modificarse en función de las necesidades del proyecto)

- **MVP de IA** (modelo entrenado + pipeline reproducible mensualmente).
- **Dashboard y API funcional**.
- **Informe ejecutivo y ético**.
- **Presentación final tipo demo empresarial**.

4. Descripción de roles y perfiles en el equipo

Cada grupo trabajará con **3 roles complementarios**, que simulan la estructura de un equipo real de Inteligencia Artificial empresarial.

El rol de **Data Product Owner (DPO)** apoyará al resto de los roles como Ingeniero de Datos, Científico de Datos.

Rol	Descripción	Principales responsabilidades
Ingeniero de Datos	Especialista en gestión, limpieza, integración y automatización de flujos de datos. Garantiza la integración, calidad y escalabilidad de datos.	- Diseñar pipelines ETL y manejo de datos nuevos. - Asegurar calidad, consistencia y trazabilidad de datos. - Versionar datasets y scripts (Git). - Desplegar infraestructura básica (APIs, dashboards, contenedores). - Automatizar procesos (actualización mensual de las tablas base). - Despliegue del pickle, API o MLflow
Científico de Datos	Responsable del análisis exploratorio, modelado y evaluación técnica de soluciones de IA. Apoya la exploración, validación y visualización de los datos. Construye la target.	- Realizar EDA y análisis estadístico. - Seleccionar características y entrenar modelos. - Ejecutar tuning de hiperparámetros y validación cruzada. - Interpretar resultados con métricas técnicas y de negocio. - Documentación EDA y análisis correlacional (selección de variables). - Encargado de la hiperparametrización del modelo. - Desarrolla visualizaciones y storytelling de los resultados (defensa)
Data Product Owner (DPO)	Conecta los resultados técnicos con los objetivos de negocio. Lidera la comunicación, planificación y presentación. Lidera el modelado y la experimentación. Apoyo al resto de los roles, tomando en cuenta que el coordina y valida decisiones, no ejecuta todo.	- Coadyuva en la definición de la hipótesis y variables objetivo. - Realiza EDA avanzada y selección del modelo. - Definir el problema de negocio y métricas de impacto. - Coordinar los sprints y priorizar tareas. - Analizar riesgos éticos y de gobernanza. - Preparar storytelling, dashboards y reportes ejecutivos. - Defiende los resultados en cada sprint con el apoyo del equipo.

5. Descripción del Proyecto de los Equipos

Cada grupo trabajará en un **proyecto aplicado de IA orientado al negocio**, basado en el dataset **Global Retail**.

El objetivo es desarrollar un **modelo predictivo y analítico** que pueda ejecutarse mensualmente con datos actualizados. Para lo cual deberán identificar cuantos meses entrarán al train, val y backTest.

5.1. Objetivo General del Proyecto

Aplicar el ciclo completo de *Machine Learning aplicado a negocios* —desde la comprensión del problema hasta la integración del modelo y su visualización de resultados— utilizando buenas prácticas de ingeniería de datos y ciencia de datos colaborativa.

5.1.1. Casos de Estudio (Docente delegará el caso de estudio – No hay cambios):

N°	Tema	Target / Variable Objetivo	Tipo de Modelo	Funcionalidad del Modelo	Temporalidad	Métricas Sugeridas
1	Predicción de satisfacción del cliente	review_score o customer_satisfaction	Regresión / Clasificación	Estimar el nivel de satisfacción del cliente según tiempos, valor y calidad del pedido.	Mensual	RMSE, F1, R ² , Gini
2	Detección de retrasos en la entrega	is_late_delivery	Clasificación	Identificar pedidos con alto riesgo de retraso antes de la entrega.	Diario / Semanal	Precision, Recall, ROC-AUC
3	Segmentación de clientes (RFM o clustering) e Identificación de clientes premium	Segmento RFM o cluster asignado y is_premium	Clustering no supervisado, Clasificación	Agrupar clientes según recencia, frecuencia y monto de compra. Detectar clientes con alto valor de vida o gasto promedio elevado.	Trimestral para el 1er modelo Mensual para 2do modelo	Silhouette Score, Dunn Index Precision, Recall, Gini
4	Predicción de cancelaciones	is_canceled	Clasificación	Anticipar qué pedidos serán cancelados para tomar acciones preventivas.	Mensual	Recall, F1-score, ROC-AUC, Gini
5	Forecast de demanda por categoría	demand_next_month	Regresión / Series temporales	Predecir las ventas futuras por categoría de producto.	Mensual	RMSE, MAPE, MAE
6	Optimización de tiempos de entrega	expected_delivery_days	Regresión	Predecir duración óptima del envío según ubicación, proveedor y método.	Diario / Semanal	RMSE, MAE
7	Análisis de churn (clientes que dejan de comprar)	is_churn	Clasificación	Detectar clientes inactivos o con riesgo de abandono.	Mensual	Recall, F1, AUC
8	Recomendación de productos personalizados	product_id_recommended	Sistema de recomendación	Sugerir productos basados en historial y similitud de compras.	Continuo	Precision@k, Recall@k
9	Predicción del método de pago más probable	payment_type	Clasificación multiclase	Predecir el método de pago preferido por cliente o pedido.	Mensual	Accuracy, Macro F1
10	Forecast de ingresos mensuales	monthly_revenue	Series temporales	Predecir los ingresos globales o por categoría del e-commerce.	Mensual	RMSE, MAPE

5.1.2. Propuesta de categorías temáticas ampliadas

Categoría Analítica	Descripción	Ejemplos de temas del módulo
Propensión de negocio (Customer Propensity)	Predice probabilidad de que un cliente realice un evento de interés (compra, cancelación, satisfacción, pago).	1, 4, 9, 2 (retraso)
Scoring / Riesgo / Valor del cliente	Asigna un puntaje a clientes, pedidos o vendedores según riesgo o valor futuro.	3 (segmentación + premium)
Churn / Retención de clientes	Identifica clientes que probablemente abandonen o reduzcan su actividad.	7, 4 (cancelación)
LTV / Valor futuro	Estima el valor económico total que un cliente o grupo de clientes aportará a la empresa.	3, 11

Next Product To Buy (NPTB) / Recomendación	Predice o sugiere productos que un cliente podría comprar próximamente.	8
Forecasting / Planificación de inventario	Predice ventas, demanda o ingresos futuros para planificación operativa.	5, 11
Optimización Operativa / Logística	Mejora procesos internos, tiempos de entrega, eficiencia logística o cumplimiento de pedidos.	6, 2

6. PLAN GENERAL DE CLASES (12 sesiones – 4 Sprints):

Semana	Clase	Enfoque	Actividades principales
1	1	Introducción al Área Metodología Ágil Storytelling	Explicar dinámica de Sprints, roles, objetivos. Introducción al dataset Olist. Taller de storytelling de datos.
1	2	Sprint 1 – Diseño y EDA inicial	Definir problema, hipótesis, variables. EDA inicial, métricas base.
1	3	Exposición Sprint 1	Presentación de avances por grupo, Análisis EDA Preliminar y posible target temporalidad. Exposición de 4 grupos.
2	4	Sprint 2 – Ingeniería de datos y pipeline	Limpieza, feature engineering, preparación de pipeline reproducible.
2	5	Avances Sprint 2	Revisión técnica de pipeline y validación de métricas.
2	6	Exposición Sprint 2	Presentaciones de modelos preliminares y defensa de la target final. Exposición de 3 grupos.
3	7	Sprint 3 – Hiperparametrización y modelo final	Tuning, validación cruzada, exportación del modelo final (pickle).
3	8	Avances Sprint 3	Ejecución de comparación de modelos.
3	9	Exposición Sprint 3	Presentaciones de performance final del modelo. Exposición de 3 grupos.
4	10	Sprint 4 – Integración y gobernanza	Integración con dashboard/API, MLflow, ética y gobernanza.
4	11	Preparación del Demo Day	Práctica de storytelling y revisión de métricas de negocio.
4	12	Demo Day (presentaciones finales)	Presentación, ejecución en vivo y defensa del MVP1.

6.1. LÓGICA DE SPRINTS

Sprint 1 – Definición del problema y EDA inicial

Duración: Semana 1

Objetivo: Formular el problema de negocio, validar hipótesis con datos y establecer métricas base.

Actividades clave:

- Definir el *problema de negocio* alineado con los objetivos estratégicos (ej. predicción de churn, satisfacción, etc.).
- Formular hipótesis (relaciones esperadas entre variables). -> Excel, Notebook
- Seleccionar variables relevantes del dataset Olist. -> 60 metadatos -> Master Table
- Generar las bases (features) que deben ser ejecutadas cada mes.-> Automatizar el proceso
- Realizar **EDA exploratorio** (tendencias, correlaciones, outliers, missing values).
- Calcular **métricas técnicas y de negocio iniciales** (baseline):
 - Técnicas: accuracy, MAE, RMSE, etc.
 - Negocio: tasa de retención, tiempos de entrega promedio, satisfacción, etc.

Entregables:

- Notebook con EDA y baseline.
- Definición del objetivo del MVP y métricas finales.
- Presentación con hipótesis y hallazgos.

- Target preliminar del modelo.

Roles:

- **Ingeniero de Datos:** estructura los datos, crea vistas/tablas unificadas, asegura calidad del dataset, automatización de features y variables calculadas.
- **Científicos de Datos:** formulan hipótesis, ejecutan EDA, definen métricas y baseline, creación de features y variables calculadas.

■ **Sprint 2 – Ingeniería de datos y pipeline reproducible**

Duración: Semana 2

Objetivo: Construir un pipeline de datos robusto y escalable, considerando incorporación mensual de nuevos datos.

Actividades clave:

- Procesos de limpieza, normalización, encoding y escalado.
- Feature engineering (creación de variables derivadas útiles).
- Diseño de **pipeline reproducible** (sklearn.pipeline o scripts modulares).
- Simular llegada de nuevos datos mensuales → actualizar modelo incrementalmente.
- Medición de métricas técnicas y de negocio finales (con pipeline completo).

Entregables:

- Script modularizado o notebook con pipeline completo.
- Documentación del flujo de datos y versión del pipeline.
- Métricas técnicas y de negocio finales (versión pipeline).

Roles:

- **Ingeniero de Datos:** diseña el pipeline, controla versiones de datos (Git), automatiza actualizaciones mensuales.
- **Científicos de Datos:** validan transformaciones, definen features, prueban diferentes enfoques de ingeniería y evalúan el impacto en el modelo. Definición y defensa final de la target.

■ **Sprint 3 – Hiperparametrización y modelo final**

Duración: Semana 3

Objetivo: Optimizar el modelo, evaluar rendimiento final y exportar el artefacto para uso mensual.

Actividades clave:

- Selección del modelo base (árboles, regresión, XGBoost, etc.).
- Aplicación de técnicas de **hiperparametrización** (GridSearchCV, Optuna, RandomSearch).
- Evaluación con validación cruzada y comparación de modelos.
- Exportación del modelo final en formato **pickle (.pkl)** para ejecución mensual.
- Documentar pipeline de retraining mensual.

Entregables:

- Modelo final (.pkl) con métricas definitivas.

- Notebook con resultados comparativos y justificación del modelo elegido.
- Gráfico de rendimiento y feature importance.

Roles:

- **Ingeniero de Datos:** implementa almacenamiento y versionado del modelo (MLflow, Git).
- **Científicos de Datos:** ejecutan tuning, evalúan modelos, seleccionan el modelo óptimo.

Sprint 4 – Integración, despliegue y gobernanza

Duración: Semana 4

Objetivo: Integrar el modelo a herramientas de negocio, implementar trazabilidad y reflexionar sobre impacto ético.

Actividades clave:

- Implementar **Dashboard / API / Streamlit app** (según tipo de modelo).
- Identificar qué proyectos pueden usar **MLflow** (monitoreo, retraining, versionado).
- Integrar métricas de negocio (ROI, satisfacción, ahorro de tiempo, etc.).
- Evaluar impacto ético, riesgos de sesgos, privacidad y gobernanza.
- Elaborar storytelling para el *Demo Day*.

Entregables:

- MVP funcional (dashboard o API) integrado al modelo.
- Informe ético y de gobernanza (2-3 páginas).
- Pitch final (presentación ejecutiva + demo).

Roles:

- **Ingeniero de Datos:** despliega el modelo (API, MLflow, Docker), integra dashboard o automatiza consultas.
- **Científicos de Datos:** documentan hallazgos, preparan storytelling y análisis de impacto.

7. EVALUACIÓN

Criterio	Peso	Evidencias
Sprint 1 – Definición y EDA	15 %	- Problema, hipótesis, baseline técnico y de negocio.
Sprint 2 – Pipeline e Ingeniería	25 %	- Pipeline modular, reproducibilidad, actualización mensual, Target Preliminar.
Sprint 3 – Modelo final	25 %	- Modelo optimizado, pickle, métricas finales, Target Final.
Sprint 4 – Integración y Gobernanza	25 %	- Dashboard/API, informe ético, storytelling, Demo Day.
Exposición de un ejemplo del Modelo Seleccionado (Totalmente diferente a los Sprints) -> Dataset diferente al Olist	10 %	Exposición del Modelo (Viernes) debe incluir: - Informe investigativo formato IEEE min. 6 páginas + 10 fuentes - Presentación PPTX

		- Ejemplo analizado y compartir código GitHub - Tiempo de exposición: 30 minutos
--	--	---

Reducción del 5% de la nota por retraso en el cumplimiento de tareas.

Bibliografía

1. Hambali, I. (2023, 12 de febrero). *Data Wrangling and Analysis in Ecommerce – Pt 1*. Medium. Recuperado de <https://imamlearnsdata.medium.com/data-wrangling-and-analysis-in-ecommerce-pt1-9721f1263f2> (Medium)
2. Olist. (s. f.). *Brazilian E-Commerce Public Dataset by Olist*. Kaggle. Recuperado de <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce/data> (Kaggle)
3. Pelathur, D. (2024). *Ecommerce Sales Analysis (SQL Project)* [Repositorio GitHub]. GitHub. Recuperado de <https://github.com/Daivik2605/Ecommerce-SQL-Analysis/tree/main> (GitHub)
4. Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2a ed.). O'Reilly Media.
5. Provost, F. & Fawcett, T. (2013). *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. O'Reilly Media.
6. Müller, A. C. & Guido, S. (2016). *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media.
7. Brown, N., Chui, M., & Manyika, J. (2011). *Are you ready for the era of “big data”*. McKinsey Quarterly.
8. ISO/IEC. (2023). *ISO/IEC 42001: Governance of Artificial Intelligence — Guidance*. Organización Internacional de Normalización.
9. European Parliament & Council. (2024). *Artificial Intelligence Act (AI Act)*. UE.
10. Leek, J. (2015). *Tidy Data*. Journal of Statistical Software, 59(10), 1-23.